

Reporte tecnico de presentacion - Colorectal AI

Fase 8: dataset, EDA, evaluacion reproducible, estadistica y validacion cruzada demo

1. Dataset y trazabilidad

Elemento	Valor
Dataset	E:\CICLO07\NCT-CRC-HE-100K-SPLIT
Imagenes	100,000
Split	train 79,994 validation 9,995 test 10,011
Resolucion	224x224 en 100,000 imagenes
Formato	TIFF en 100,000 imagenes
Corruptas	0
Duplicadas	0
Fingerprint backend	4adeec449438176b33beb06f1a6e9e06437e7bda7294fbc92b96ca4618174ee3

Interpretacion: El dataset esta particionado y trazado con manifiestos reproducibles. No se detectaron imagenes corruptas ni duplicados exactos, lo que reduce riesgos de errores de lectura y fuga de informacion entre particiones durante la evaluacion.

Distribucion por clase


Conteo total por clase en NCT-CRC-HE-100K

ADI		10,407
BACK		10,566
DEB		11,512
LYM		11,557
MUC		8,896
MUS		13,536
NORM		8,763
STR		10,446
TUM		14,317


Interpretacion: La distribucion por clase no es perfectamente uniforme: algunas categorias tienen mas muestras que otras. Por eso se usan splits estratificados y metricas macro, evitando que las clases con mas imagenes dominen la interpretacion del desempeno.

Distribucion por particion

Split estratificado train / validation / test por clase




Interpretacion: El split conserva proporciones similares por clase en train, validation y test. Esto hace que el conjunto de evaluacion sea comparable al entrenamiento y reduce el riesgo de que una particion quede artificialmente mas facil o mas dificil.




ADI




BACK




DEB




LYM




MUC




MUS



NORM



STR



TUM


Interpretacion: El montaje confirma visualmente que el sistema lee parches histopatologicos reales desde disco y que todas las clases configuradas tienen ejemplos. Es una validacion visual complementaria a los conteos y fingerprints.

2. Evaluacion reproducible de modelos actuales

Modelo	Muestras	Accuracy	Macro F1	Macro AUC	MCC
cnn_simple	45	44.44%	0.5644	0.8300	0.3872
best_model	45	11.11%	0.2000	0.5000	0.0000
mobilenetv2	45	11.11%	0.2000	0.5000	0.0000
hybrid_attention	45	11.11%	0.2000	0.4022	0.0000
hybrid_autoencoder	45	11.11%	0.2000	0.4789	0.0000
resnet50v2	45	2.22%	0.0909	0.4761	-0.1107

Evaluacion reproducible sobre test


Comparacion de modelos con predicciones reales



Interpretacion: La evaluacion demo usa predicciones reales del conjunto test con una muestra estratificada. En esta corrida rapida, CNN Simple obtiene la mejor combinacion de accuracy, Macro F1, AUC y MCC; el valor principal es demostrar que el pipeline genera artefactos trazables, no cerrar una conclusion clinica final.

Comparacion ROC de modelos - clase TUM


Curvas one-vs-rest calculadas desde predicciones reales de la Fase 4 demo.



Interpretacion

Una curva mas cercana al borde superior izquierdo indica mejor separacion para la clase TUM. AUC=0.5 equivale aproximadamente a azar.

Interpretacion: La comparacion ROC/AUC muestra la capacidad de separacion para TUM en modo one-vs-rest. Una curva mas cercana a la esquina superior izquierda y un AUC mayor indican mejor discriminacion; AUC cercano a 0.5 equivale aproximadamente a azar.



Interpretacion: Los graficos de entrenamiento heredados muestran la evolucion historica de accuracy y loss. Sirven para explicar convergencia y posible sobreajuste, aunque no corresponden a un reentrenamiento ejecutado durante esta demo urgente.

Matriz de confusion: cnn_simple

	ADI	BACK	DEB	LYM	MUC	MUS	NORM	STR	TUM
ADI	5	0	0	0	0	0	0	0	0
BACK	0	5	0	0	0	0	0	0	0
DEB	1	0	0	0	1	1	1	0	1
LYM	0	0	0	5	0	0	0	0	0
MUC	1	1	0	0	1	1	0	0	1
MUS	0	1	1	0	0	3	0	0	0
NORM	0	1	0	0	1	2	1	0	0
STR	0	1	0	0	1	3	0	0	0
TUM	0	0	1	0	1	2	0	1	0

Interpretacion: La matriz de confusion muestra el patron de errores por clase. Permite detectar si el modelo concentra aciertos en pocas categorias, si confunde tejidos similares o si existe sesgo hacia una clase; por eso complementa las metricas agregadas.


3. Pruebas estadísticas pareadas

Prueba	Resultado	Interpretacion
McNemar	$p=0.001319$	Diferencia significativa en aciertos/errores pareados.
Bootstrap accuracy	diff=-0.3333; IC95 -0.4783 a -0.1883	El intervalo no cruza cero en la muestra demo.
DeLong AUC TUM	$p=0.000045$; diff=-0.3100	Diferencia significativa de AUC para la clase TUM.
Holm-Bonferroni	Aplicado	Controla error por multiples pruebas.

Interpretacion: Las pruebas son pareadas: ambos modelos se comparan sobre las mismas imagenes, etiquetas, particion y fingerprint. McNemar analiza cambios en acierto/error, DeLong compara AUC para TUM, bootstrap estima intervalos de confianza y Holm-Bonferroni corrige multiples pruebas. Para conclusion final se debe escalar la muestra.

McNemar - contingencia visual

La prueba se enfoca en los casos discordantes: solo modelo 1 vs solo modelo 2.



Interpretacion: McNemar se interpreta mirando especialmente los casos discordantes: solo modelo 1 contra solo modelo 2. Un desbalance fuerte entre esos dos grupos respalda diferencia estadística de aciertos/errores.

DeLong AUC - clase TUM

Comparacion de AUC pareado; mayor AUC indica mejor separacion de la clase.



Interpretacion: DeLong compara el AUC de dos modelos para la misma clase y las mismas muestras. Un AUC mas alto indica mayor capacidad de separacion, y el p-value permite defender si la diferencia es estadisticamente significativa.

Bootstrap pareado - diferencias con IC95


Diferencia = modelo 1 menos modelo 2. Si el intervalo no cruza cero, la diferencia es consistente.



Interpretacion: Bootstrap pareado visualiza diferencias de metricas con IC95. Si el intervalo no cruza cero, la diferencia observada es consistente en la muestra evaluada.

P-values y Holm-Bonferroni

Comparacion de p-values originales y ajustados; linea roja = 0.05.




Interpretacion: Holm-Bonferroni ajusta los p-values de McNemar y DeLong para reportar varias pruebas reduciendo el riesgo de falsos positivos.

4. Validacion cruzada demo

Modelo	Folds	Muestras/fold	Accuracy media	Accuracy std	Macro F1 media	Macro AUC media	MCC media
cnn_simple	5	18	48.89%	0.0648	0.7203	0.8326	0.4569
best_model	5	18	11.11%	0.0000	0.2000	0.5000	0.0000

Validacion cruzada demo K=5

Promedio de metricas por fold usando muestras estratificadas



Interpretacion: Se generaron folds estratificados reales K=5 y balanceados. La demo evalua modelos existentes para calcular medias y desviaciones rapidamente; la version cientifica final debe reentrenar el modelo dentro de cada fold para medir generalizacion de entrenamiento.

5. Conclusion para exposicion

El proyecto ya demuestra un flujo completo: dataset externo sin subir a GitHub, particiones reproducibles, EDA con graficas, evaluacion con predicciones reales, pruebas estadisticas pareadas y validacion cruzada demo. Para una entrega final cientifica se recomienda ejecutar evaluacion amplia sobre mas muestras y entrenar por fold.